

Universidad de San Carlos de Guatemala

Escuela de postgrado

Maestría en Ingeniería con especialidad en ciencias de la computación con
especialización en ciencia de datos

Minería Avanzada de Datos



Predicciones Copa del Mundo 2026

<https://github.com/jamesg19/fifa-wc-predictor-crisp-dm>

Eriksson José Hernández López - 999017424

James Osmin Gramajo Carcamo - 999015976

Jimmy Daniel Larios Martínez - 999017167

Willy Jessiel Ardiano Juárez - 999017224

Guatemala, Julio 2026

1. Resumen ejecutivo

Se desarrolló un modelo de clasificación multiclase para predecir el resultado del equipo local (Derrota / Empate / Victoria) en partidos internacionales de fútbol, con énfasis en los encuentros del FIFA World Cup. Se compararon cuatro algoritmos supervisados sobre 49,502 partidos históricos (1872–2026) enriquecidos con variables de forma reciente, historial directo (head-to-head) y contexto del partido.

El mejor modelo fue Gradient Boosting, con 56.9 % de exactitud (accuracy) en el conjunto de prueba y F1-macro de 0.428, superando la meta de negocio de 55 % de accuracy pero quedando por debajo de la meta de F1-macro ≥ 0.50 , debido a la dificultad estructural para predecir empates.

2. Algoritmo y modelo documentado

El problema se formuló como clasificación supervisada multiclase con variable objetivo resultado, codificada como 0 = Derrota, 1 = Empate, 2 = Victoria (desde la perspectiva del equipo local). Se entrenaron y compararon cuatro algoritmos con semilla fija (SEED = 42) y validación cruzada estratificada de 5 particiones (StratifiedKFold, shuffle=True):

Algoritmo	Configuración	Rol
Regresión Logística	max_iter=1000, variables estandarizadas con StandardScaler	Modelo base lineal (baseline)
Random Forest	n_estimators=200, n_jobs=-1	Ensamble por bagging
Gradient Boosting	n_estimators=200 (sklearn)	Ensamble secuencial — modelo ganador
XGBoost	n_estimators=200, eval_metric=mlogloss	Boosting optimizado

Modelo seleccionado: GradientBoostingClassifier. Fue elegido por presentar la mayor exactitud tanto en validación cruzada (0.559 ± 0.003) como en el conjunto de prueba (0.569). El modelo genera además las probabilidades por clase (predict_proba), lo que permite expresar cada predicción como una distribución de probabilidad (Prob_Derrota, Prob_Empate, Prob_Victoria) en lugar de una etiqueta única.

Como aplicación derivada, el modelo entrenado se utilizó en una simulación Monte Carlo de 5,000 corridas para estimar el TOP 4 del Mundial 2026, decidiendo cada llave con la probabilidad de victoria asignada por el modelo.

3. Proceso metodológico (CRISP-DM)

Fase 1 — Comprensión del negocio

Objetivo: predecir el resultado del equipo local en partidos del FIFA World Cup a partir del historial de partidos internacionales. Criterios de éxito definidos: accuracy $\geq 55\%$, F1-macro ≥ 0.50 y comparación de al menos cuatro algoritmos. Entregables: dataset enriquecido para Power BI, predicciones con probabilidades e importancia de variables.

Fase 2 — Comprensión de los datos

Fuente de datos: repositorio público martj42/international_results (GitHub), archivo results.csv, descargado en tiempo de ejecución mediante requests desde:

https://raw.githubusercontent.com/martj42/international_results/master/results.csv

Contiene el registro de partidos internacionales masculinos desde 1872. La descarga produjo 49,505 filas $\times$ 9 columnas. El notebook incluye un mecanismo de contingencia que genera un dataset sintético si falla la descarga; en la ejecución documentada la descarga fue exitosa (mensaje "[OK] Datos descargados").

Hallazgos del análisis exploratorio:

- Solo 3 valores nulos (en home_score y away_score); el resto de columnas está completo.
- Promedio de goles: 1.76 del local y 1.18 del visitante — evidencia cuantitativa de la ventaja de campo.
- Distribución global de resultados: Victoria 49.0 %, Derrota 28.3 %, Empate 22.7 % (clases desbalanceadas).
- En los 1,064 partidos de FIFA World Cup el sesgo local se atenúa: Victoria 45.6 %, Derrota 32.0 %, Empate 22.4 %.
- Torneos más frecuentes: Amistosos (18,388), Eliminatorias del Mundial (8,771) y Eliminatorias UEFA Euro (2,824).

Fase 3 — Preparación de los datos

Se ordenó el dataset cronológicamente y se derivó la variable objetivo por comparación de marcadores. La ingeniería de características se realizó con dos funciones que solo consultan partidos anteriores a la fecha del encuentro (`df["date"] < fecha`), evitando fuga de información temporal (data leakage):

- `calcular_forma(equipo, fecha, ventana=5)`: puntos acumulados, goles a favor, goles en contra y diferencia de gol en los últimos 5 partidos del equipo, considerando tanto sus juegos de local como de visitante.
- `calcular_h2h(local, visitante, fecha, ventana=10)`: victorias, empates y derrotas del equipo local en los últimos 10 enfrentamientos directos.

Se añadieron variables de contexto (campo neutral, si es Mundial, año, mes) y se codificaron los nombres de los equipos con LabelEncoder. El conjunto final quedó en 49,502 filas × 20 variables predictoras.

Partición temporal (no aleatoria): 80 % de entrenamiento (39,601 partidos, hasta 2015) y 20 % de prueba (9,901 partidos, desde 2016). Este esquema replica el uso real del modelo — predecir el futuro con información del pasado. Las variables se estandarizaron solo para la Regresión Logística.

Fase 4 — Modelado

Entrenamiento de los cuatro algoritmos con validación cruzada estratificada de 5 particiones sobre el conjunto de entrenamiento y evaluación posterior sobre el conjunto de prueba (2016 en adelante).

Fase 5 — Evaluación

Modelo	CV Accuracy (5-fold)	Test Accuracy	F1-macro
Gradient Boosting	0.559 ± 0.003	0.569	0.428
Regresión Logística	0.552 ± 0.003	0.559	—
XGBoost	0.548 ± 0.003	0.554	—
Random Forest	0.547 ± 0.003	0.551	—

Reporte de clasificación del modelo ganador (Gradient Boosting, n = 9,901):

Clase	Precisión	Recall	F1-score
Derrota (n=2,874)	0.54	0.54	0.54
Empate (n=2,310)	0.38	0.03	0.05
Victoria (n=4,717)	0.59	0.85	0.70

Clase	Precisión	Recall	F1-score
Promedio macro	0.50	0.47	0.43

El modelo identifica bien victorias y derrotas, pero prácticamente no logra predecir empates (recall = 0.03): al ser la clase minoritaria y la de menor separabilidad, el modelo casi nunca la elige. Esto explica la brecha entre el accuracy (56.9 %) y el F1-macro (0.428).

Variables más importantes (feature_importances_): h2h_v (0.162), dif_gc (0.159), h2h_d (0.159), dif_pts (0.156) y dif_gf (0.061). Es decir, el historial directo entre selecciones y las diferencias relativas de forma concentran la capacidad predictiva; las variables de identidad (home_enc, away_enc) y de calendario aportan poco.

Fase 6 — Despliegue

Exportación a output_powerbi/fifa_predicciones_powerbi.xlsx con cuatro hojas: Todos_Partidos (49,502 registros con predicción, probabilidades y bandera de acierto), World_Cup (1,061 partidos), Evaluacion_Modelos e Importancia_Vars; además de los CSV y gráficos (matriz de confusión, importancia de variables, EDA) para el tablero de Power BI.

4. Diccionario de variables

4.1 Variables originales de la fuente (results.csv)

Variable	Tipo	Descripción
date	fecha	Fecha del partido
home_team	texto	Selección local
away_team	texto	Selección visitante
home_score	numérica	Goles del equipo local (tiempo reglamentario)
away_score	numérica	Goles del equipo visitante
tournament	texto	Competencia (FIFA World Cup, Friendly, etc.)
city / country	texto	Sede del encuentro — no utilizadas en el modelo
neutral	booleana	Indica si se jugó en campo neutral

4.2 Variables derivadas utilizadas en el modelo (FEATURE_COLS, 20 variables)

Variable	Grupo	Descripción
home_pts_f	Forma local	Puntos del local en sus últimos 5 partidos (3/1/0)
home_gf_f	Forma local	Goles a favor del local en los últimos 5 partidos
home_gc_f	Forma local	Goles en contra del local en los últimos 5 partidos
home_dif_f	Forma local	Diferencia de gol del local (gf – gc)
away_pts_f	Forma visitante	Puntos del visitante en sus últimos 5 partidos
away_gf_f	Forma visitante	Goles a favor del visitante
away_gc_f	Forma visitante	Goles en contra del visitante
away_dif_f	Forma visitante	Diferencia de gol del visitante
dif_pts	Comparativa	home_pts_f – away_pts_f (4.ª más importante)

Variable	Grupo	Descripción
dif_gf	Comparativa	home_gf_f – away_gf_f (5. ^a más importante)
dif_gc	Comparativa	home_gc_f – away_gc_f (2. ^a más importante)
h2h_v	Head-to-head	Victorias del local en los últimos 10 duelos directos (1. ^a)
h2h_e	Head-to-head	Empates en los últimos 10 duelos directos
h2h_d	Head-to-head	Derrotas del local en los últimos 10 duelos (3. ^a)
neutral	Contexto	Campo neutral (1) o no (0)
es_wc	Contexto	El partido es del FIFA World Cup (1) o no (0)
anio	Contexto	Año del partido
mes	Contexto	Mes del partido
home_enc	Identidad	Código numérico del equipo local (LabelEncoder)
away_enc	Identidad	Código numérico del equipo visitante (LabelEncoder)

Variable objetivo: resultado (0 = Derrota, 1 = Empate, 2 = Victoria, desde la perspectiva del local).
Variables descartadas: city, country y resultado_raw (auxiliar del EDA); home_score y away_score se excluyen del modelo por construir la etiqueta (evitan fuga de información) y solo se conservan como metadatos para el tablero.

5. Conclusiones

- Gradient Boosting fue el mejor de los cuatro algoritmos evaluados, con 56.9 % de accuracy y F1-macro de 0.428 sobre 9,901 partidos de prueba (2016–2026). Se cumplió el criterio de accuracy $\geq 55\%$, pero no el de F1-macro ≥ 0.50 .
- Las diferencias entre modelos son marginales (0.551–0.569 de accuracy; ~1.8 puntos porcentuales entre el mejor y el peor). La limitación no está en el algoritmo, sino en la información disponible: el techo lo impone el conjunto de variables, no la familia de modelos.
- El empate es la clase estructuralmente más difícil: con 22.7 % de prevalencia y sin un patrón claro, el modelo lo predice casi nunca (recall 0.03). Esto es coherente con la literatura de predicción deportiva y sugiere estrategias como ponderación de clases, umbrales de probabilidad o un enfoque ordinal.
- La señal predictiva se concentra en el enfrentamiento directo (h2h_v, h2h_d) y en las diferencias relativas de forma (dif_gc, dif_pts): el contexto histórico entre selecciones pesa más que el rendimiento absoluto individual o la identidad codificada del equipo.
- Los datos confirman la ventaja de localía (49.0 % de victorias del local, 1.76 vs. 1.18 goles), aunque se atenúa en el Mundial (45.6 %), donde la mayoría de sedes son neutrales.
- La partición temporal (entrenar hasta 2015, probar desde 2016) y el cálculo de features solo con partidos anteriores garantizan que la evaluación no esté contaminada por fuga de información; el 56.9 % es por tanto una estimación realista, no optimista.

Limitaciones y trabajo futuro

- El modelo no incorpora ranking FIFA, valor de plantilla, lesiones, descanso entre partidos ni condiciones de sede, todas variables con potencial explicativo.
- Se entrena con todos los torneos (amistosos incluidos), cuya dinámica difiere de la de un Mundial; una alternativa es ponderar o filtrar por competitividad del torneo.

- En la simulación del Mundial 2026 los nombres de las selecciones se escribieron en español ("Francia", "Espana"), mientras que el dataset los registra en inglés ("France", "Spain"). Como consecuencia, `calcular_forma` devolvió ceros para cinco de los seis equipos y su codificación quedó en 0, por lo que las probabilidades del TOP 4 no son confiables. Corregir la nomenclatura a la del dataset es un requisito previo para validar ese apartado.
- Ninguno de los modelos fue optimizado por búsqueda de hiperparámetros (`GridSearchCV` / `RandomizedSearchCV`); se usaron configuraciones por defecto con `n_estimators=200`.